

# 计算机保研面试\_数学常见题

---

## 计算机保研面试\_数学常见题

### 1 线性代数

- (1) 余子式
- (2) 行列式
- (3) 矩阵的秩, 满秩, 不满秩
- (4) 矩阵的迹
- (5) 线性方程组解的情况
- (6) 线性相关, 线性无关
- (7) 方阵可逆的充要条件
- (8) 向量空间, 线性空间
- (9) 向量空间的基和维数
- (10) 矩阵的特征值和特征向量
- (11) 向量正交, 矩阵正交
- (12) 正交矩阵
- (13) 相似矩阵
- (14) 合同矩阵
- (15) 正定矩阵
- (16) 范数
- (17) 内积
- (18) 特征值分解
- (19) 奇异值分解

### 2 概率论

- (1) 全概率公式和贝叶斯公式
- (2) 大数定律
- (3) 中心极限定理
- (4) 变量与随机变量有什么区别?
- (5) 联合概率、边缘概率、条件概率
- (6) 先验概率、后验概率
- (7) 常见的概率分布
- (8) 若干个高斯分布相加/相乘后得到的分布是什么
- (9) 期望和方差
- (10) 协方差和相关系数
- (11) 独立和不相关的区别
- (12) 独立和互斥的关系
- (13) 古典概型和几何概型的区别
- (14) 概率密度函数
- (15) 极大似然估计
- (16) 什么是假设和检验
- (17) 机器学习为什么要使用概率?
- (18) 不均匀硬币产生等概率
- (19) 伪随机数产生均匀分布
- (20) 由均匀分布产生高斯分布

### 3 微积分

### 4 离散数学

- (1) 自反、对称、传递
- (2) 对称传递能不能推出自反性?
- (3) 自反性存在有什么意义?
- (4) 等价关系和等价类
- (5) 偏序关系

# 1 线性代数

## (1) 余子式

- 余子式：n 阶行列式中，划去  $a_{ij}$  所在的第  $i$  行与第  $j$  列的元，剩下的元所构成的  $n-1$  阶行列式称为  $a_{ij}$  的余子式。
- 代数余子式：在余子式前面乘上  $(-1)^{i+j}$

## (2) 行列式

- 行列式  $\det(A)$ ，是一个将方阵  $A$  映射到实数的函数。
- 几何意义：行列式是有向面积或体积的概念在欧几里得空间中的推广，它描述了一个线性变换对“体积”的影响。
  - 2 阶行列式代表的是平面内的面积。
  - 3 阶行列式代表的是立体空间内的体积。
  - 4 阶行列式是 4 维空间里的超体积。
- 计算方法：行列式等于它任意一行（列）的各元素与其对应的代数余子式乘积之和。
- 行列式和矩阵特征值的关系：行列式等于矩阵特征值的乘积。

## (3) 矩阵的秩，满秩，不满秩

- 矩阵的秩
  - 子式角度：矩阵的非零子式的最高阶数。

$k$  阶子式：在矩阵中取  $k$  行  $k$  列，交叉处的  $k^2$  个元素按原顺序构成的行列式。
  - 线性无关角度：矩阵的所有行向量中极大线性无关组的元素个数。
  - 标准型角度：先将矩阵转化为行阶梯型，其非零行个数就是矩阵的秩。
- 满秩：一个秩为  $n$  的矩阵满秩意味着存在一个  $n$  阶子式不为 0。
- 不满秩：假设其秩为  $r$ ，意味着存在一个  $r$  阶子式不为 0，其所有阶数大于  $r$  的子式都为 0。

## (4) 矩阵的迹

方阵  $A$  的迹：对角线元素之和。

### (5) 线性方程组解的情况

- 齐次线性方程组  $AX = 0$  :  $r(A) = n$ , 有惟一零解;  $r(A) < n$ , 有无穷多解。
- 非齐次线性方程组  $AX = b$  :  $r(A) \neq r([A, b])$ , 无解;  $r(A) = r([A, b]) = n$ , 有唯一解;  $r(A) = r([A, b]) < n$ , 有无穷多解。

### (6) 线性相关, 线性无关

- 对于线性空间中的  $n$  个向量, 若存在  $n$  个不全为 0 的常数, 使得这  $n$  个常数与  $n$  个向量对应乘积加和等于 0, 则称这  $n$  个向量线性相关, 如果不存在这样的  $n$  个常数, 称之为线性无关。
- 几何意义:  $n$  个向量线性无关等价于他们所张成的  $n$  维体的体积不为 0; 若线性相关, 则体积为 0。

### (7) 方阵可逆的充要条件

1. 方阵  $A$  可逆。
2.  $A$  是非奇异矩阵 ( $|A| \neq 0$ ) 。
3.  $A$  满秩。
4.  $A$  可以表示成有限个初等矩阵的乘积。
5. 特征值没有 0。
6. 矩阵线性无关。

### (8) 向量空间, 线性空间

- 向量空间: 所有  $n$  维向量构成的集合称为  $n$  维向量空间。
- 线性空间: 若非空集合  $V$  上满足加法封闭性和乘法封闭性, 并且还满足以下 8 条性质: 加法交换律、加法结合律、加法零元、加法逆元、数乘幺元、数乘结合律、数乘分配律 (2个), 则称集合  $V$  是线性空间。
- 两者的关系: 线性空间包含向量空间, 除了向量空间, 线性空间还包括多项式空间、矩阵空间等。

### (9) 向量空间的基和维数

- 基: 在向量空间  $V$  中可以找到  $n$  个向量, 这  $n$  个向量线性无关, 并且线性空间  $V$  中的任意一个向量都和这  $n$  个向量线性相关, 那么这  $n$  个向量就称作线性空间  $V$  的一个基。
- 维数: 基中所含向量个数。

### (10) 矩阵的特征值和特征向量

- 含义: 矩阵就是一个线性变换, 它作用于特征向量后, 向量方向保持不变 (不发生旋转变换), 进行某一比例的伸缩变换, 这个比例就是特征值, 即

$$AX = \lambda X, \text{ 其中 } X \text{ 是 } A \text{ 的特征向量, } \lambda \text{ 是 } A \text{ 的特征值}$$

- 特征值和特征向量的关系
  - 特征值和特征向量是一对多的关系，一个特征值可能对应多个特征向量，一个特征向量只能属于一个特征值。
  - 属于不同特征值的特征向量一定线性无关。
  - 设  $\lambda$  是  $n$  阶方阵  $A$  的一个  $k$  重特征值 ( $\lambda$  为特征方程的  $k$  重根)，对应于  $\lambda$  的线性无关的特征向量的最大个数为  $l$ ，则  $k \geq l$ ，即特征值  $\lambda$  的**代数重数不小于几何重数**。
- 应用：奇异值分解、主成分分析。

### (11) 向量正交，矩阵正交

- 向量正交：在正交向量组中，任意两个向量的数量积为 0。
- 矩阵正交：两个矩阵正交，表示这两个矩阵相乘结果为单位矩阵。

### (12) 正交矩阵

$A$  是正交矩阵  $\iff A^T A = E \iff A^T = A^{-1} \iff A$  的各列向量是标准正交向量组（都是单位向量，且两两正交）。

### (13) 相似矩阵

- 相似矩阵：对于两个矩阵  $A, B$ ，如果存在一个可逆矩阵  $P$ ，使得矩阵  $P^{-1}AP = B$ ，那么矩阵  $A$  相似于矩阵  $B$ 。
- 意义：相似的矩阵是同一个线性变换在不同基/坐标系下的不同描述。
- 性质：两个相似的矩阵具有相同的秩、迹、行列式、特征值，但特征向量未必相同。
- 补充：实对称矩阵有相同的特征值则必相似。

因为实对称矩阵可对角化，对角化后对角上就是特征值。

### (14) 合同矩阵

设  $A, B$  是两个方阵，若存在可逆矩阵  $C$ ，使得  $C^T A C = B$ ，则称方阵  $A, B$  合同，记作  $A \simeq B$ 。

### (15) 正定矩阵

- 正定矩阵：假设一个实对称矩阵  $A$ ，对于任意一个非零的列向量  $S$ ，都有  $S^T A S > 0$ ，则该矩阵正定。
- 半正定矩阵：就是把上面的  $>$  改成  $\geq$
- 性质：
  - 特征值全为正。
  - 各阶主子式大于零。

- 对称矩阵  $A$  正定的充要条件： $A$  的特征值全为正。

## (16) 范数

- $R^n$  上的**向量**  $x = (x_1, \dots, x_n)^T$  的范式（离散型范数公式）：

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

$$\|x\|_2 = \left(\sum_{i=1}^n x_i^2\right)^{\frac{1}{2}}$$

带权重的形式（以2-范数为例）： $\|x\|_2 = \left(\sum_{i=1}^n w_i x_i^2\right)^{\frac{1}{2}}$

- $C[a, b]$  上的**函数**  $f(x)$  的范式（连续型范数公式）：

$$\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|$$

$$\|f\|_1 = \int_a^b |f(x)| dx$$

$$\|f\|_2 = \left(\int_a^b f^2(x) dx\right)^{\frac{1}{2}}$$

带权重的形式（以2-范数为例）： $\|f(x)\|_2 = \left(\int_a^b \rho(x) f^2(x) dx\right)^{\frac{1}{2}}$

- $R^{n \times n}$  上的**矩阵**  $A$  的范式：

$$\text{行范式} : \|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$\text{列范式} : \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$\text{谱范式} : \|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}, \text{其中 } \lambda_{\max} \text{ 表示最大特征值}$$

$$F \text{ 范式} : \|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

$A = \begin{bmatrix} 4 & -3 \\ -1 & 6 \end{bmatrix}$  的范式：

$$\text{行范式} : \|A\|_{\infty} = \max \{ \text{各行绝对值之和} \} = \max \{ 7, 7 \} = 7$$

$$\text{列范式} : \|A\|_1 = \max \{ \text{各列绝对值之和} \} = \max \{ 5, 9 \} = 9$$

$$F \text{ 范式} : \|A\|_F = \sqrt{4^2 + 3^2 + 1^2 + 6^2} = 7.87401$$

$$\text{谱范式} : \|A\|_2 = \sqrt{\lambda_{\max} \left( \begin{bmatrix} 17 & -18 \\ -18 & 45 \end{bmatrix} \right)} = 7.335087491$$

怎么求矩阵  $A$  的最大特征值？ $|\lambda E - A| = 0$ ，然后求  $\lambda$  的最大解

## (17) 内积

- $R^n$  上的**向量**  $x, y$  的内积（离散型内积公式）：

$$(x, y) = \sum_{i=1}^n w_i x_i y_i$$

$w_i$  是权重

- $C[a, b]$  上的**函数**  $f(x), g(x)$  的内积（连续型内积公式）：

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx$$

$\rho(x)$  是权函数, 一般为  $1, \frac{1}{\sqrt{1-x^2}}, \sqrt{1-x^2}$

## (18) 特征值分解

- 特征值分解 (谱分解): 对于一个方阵  $A$ ,  $\lambda_1 \leq \dots \leq \lambda_n$  是  $A$  的  $n$  个特征值,  $w_1, w_2, w_n$  是其对应的  $n$  个线性无关的特征向量, 则存在正交矩阵  $W$ , 使得

$$W^{-1}AW = W^TAW = \Lambda = \begin{pmatrix} \lambda_1 & & \\ & \dots & \\ & & \lambda_n \end{pmatrix}$$

其中  $W$  是将  $A$  的  $n$  个特征向量单位化后组成的  $n \times n$  矩阵。

- 意义: 将一个方阵对应的线性变换转化为“旋转——拉伸——旋转”变换。

正交矩阵对应旋转变换, 对角矩阵对应拉伸变换。

## (19) 奇异值分解

奇异值分解 (SVD): 特征值分解的扩展, 适用于任意矩阵  $A_{m \times n}$ 。

$$A = U\Sigma V^T$$

- $U_{m \times m}$ : 对称矩阵, 由  $AA^T$  的所有特征向量组成, 其中每个特征向量叫做  $A$  的左奇异向量。
- $V_{n \times n}$ : 对称矩阵, 由  $A^T A$  的所有特征向量组成, 其中每个特征向量叫做  $A$  的右奇异向量。
- $\Sigma_{m \times n}$ : 除了对角线上是奇异值, 其他全为 0, 奇异值  $\sigma_i$  由  $Av_i = \sigma_i u_i$  求得。

# 2 概率论

## (1) 全概率公式和贝叶斯公式

- 全概率公式
  - 由因推果。造成某种结果, 有多种原因, 求发生这种结果的概率是多少?
  - 假设造成结果  $A$  的原因有  $B_1, B_2, \dots, B_n$ , 则  $A$  发生的概率为每个原因发生的概率乘以在这种情况下  $A$  发生的条件概率的加和, 即

$$p(A) = \sum_{i=1}^n p(B_i)p(A|B_i)$$

- 贝叶斯公式
  - 由果推因。已知某结果的发生概率, 求造成该结果的第  $i$  个原因的概率是多少?
  - 假设结果  $A$  发生的概率为  $p(A)$ , 原因可能有  $B_1, B_2, \dots, B_n$ , 则  $A$  是由  $B_i$  造成的概率  $p(B_i|A)$  这样求

先用条件概率公式计算，再用全概率公式替换分母

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

## (2) 大数定律

- 大数定律：当重复试验的次数很大时，随机变量的**均值**依概率收敛于自己的**期望**，“偶然中包含着某种必然”。
- 意义：大数定律将数理统计中的均值和概率论中的期望联系在了一起。
- 三种表述
  - 切比雪夫大数定律：随机变量  $X_1, X_2, \dots, X_n$  独立、期望  $EX_i$  和方差  $DX_i$  都存在、方差  $DX_i$  有一致上界（即每个方差都有上界且收敛速度接近），则**样本均值收敛于自己的期望**，即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n EX_i$$

- 伯努利大数定律：对于  $X \sim B(n, p)$ ，当  $n$  很大时，有  $\frac{X}{n} \xrightarrow{P} p$ 。即大量独立重复实验后，随机事件发生的**频率收敛于概率**。
- 辛钦大数定律：随机变量  $X_1, X_2, \dots, X_n$  独立同分布、期望  $EX = \mu$  存在，当  $n$  很大时，他们的**算术平均值依概率收敛于期望**，即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

## (3) 中心极限定理

- 独立同分布中心极限定理：随机变量  $X_1, X_2, \dots, X_n$  独立同分布，期望  $EX = \mu$ ，方差  $DX = \sigma^2 > 0$ ，当  $n$  很大时，则均值  $\bar{X}_n$  近似服从正态分布  $N(\mu, \sigma^2/n)$ ，即

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} < a\right) = \Phi(a) = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

- 拉普拉斯 / 二项分布中心极限定理：是独立同分布中心极限定理的特殊情况，设随机变量  $\xi_n$  服从二项分布  $B(n, p)$ ， $\xi_n$  可视为  $n$  个独立同分布的 0-1 分布随机变量的和，当  $n$  很大时，则均值  $\xi_n$  近似服从正态分布  $N(np, np(1-p))$ ，即

$$\lim_{n \rightarrow \infty} P\left(\frac{\xi_n - np}{\sqrt{np(1-p)}} < a\right) = \Phi(a)$$

该定理表明：当试验次数  $n$  足够大时，二项分布近似于正态分布。

- 应用：如某炮兵阵地对敌人的防御地段进行100次射击，每次射击中炮弹的命中数是一个随机变量，其期望为2，方差为1.69，求在100次射击中有180颗到220颗炮弹命中目标的概率。

#### (4) 变量与随机变量有什么区别？

- 变量：描述确定性现象，取值固定唯一。
- 随机变量：描述随机现象，取值有多个，且每个取值都有一定的概率。

#### (5) 联合概率、边缘概率、条件概率

- 联合概率：两个事件共同发生的概率， $P(A, B)$
- 边缘概率：某个事件发生的概率，与其它事件无关， $P(A)$
- 条件概率：在事件  $B$  已经发生的条件下，事件  $A$  发生的概率， $P(A|B)$

#### (6) 先验概率、后验概率

- 先验概率：根据以往经验得到的概率，是“由因推果”问题中的“因”，不需要使用贝叶斯公式计算。
- 后验概率：得到结果后重新修正的概率，是“由果推因”问题中的“因”，需使用贝叶斯公式计算。
- 计算后验概率需要用到先验概率。

#### (7) 常见的概率分布

分布	分布列 $p_k$ 或分布密度 $p(x)$	期望	方差
0-1 分布 $b(1, p)$	$p_k = p^k(1-p)^{1-k}, \quad k = 0, 1$	$p$	$p(1-p)$
二项分布 $b(n, p)$ $n$ 重伯努里试验成功事件的次数 有放回抽 $n$ 件，其中一种的件数	$p_k = \binom{n}{k} p^k(1-p)^{n-k}, \quad k = 0, 1, \dots, n$	$np$	$np(1-p)$
泊松分布 $P(\lambda)$ 单位时间的发生次数 单位面积 / 体积的数量	$p_k = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$	$\lambda$	$\lambda$
超几何分布 $h(n, N, M)$ 不放回抽 $n$ 件，其中一种的件数	$p_k = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, r, \quad r = \min\{M, n\}$	$n \frac{M}{N}$	$\frac{nM(N-M)(N-n)}{N^2(N-1)}$
几何分布 $Ge(p)$ 事件首次出现时的试验次数	$p_k = (1-p)^{k-1} p, \quad k = 1, 2, \dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
负二项分布 $Nb(r, p)$ 事件第 $r$ 次出现时的试验次数	$p_k = \binom{k-1}{r-1} (1-p)^{k-r} p^r, \quad k = r, r+1, \dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
均匀分布 $U(a, b)$	$p(x) = \frac{1}{b-a}, \quad a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布 $N(\mu, \sigma^2)$	$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty$	$\mu$	$\sigma^2$
指数分布 $Exp(\lambda)$ 一般为寿命	$p(x) = \lambda e^{-\lambda x}, \quad x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

补充几点：



- 0-1 分布又叫伯努利分布、两点分布。
- 泊松分布
  - $\lambda$ : 单位时间 / 面积内随机事件的平均发生次数
  - 泊松分布和二项分布的关系: 当二项分布的  $n$  很大而  $p$  很小时, 泊松分布可作为二项分布的近似
  - 应用: 描述单位时间内随机事件发生的次数, 如: 一天内电路受电磁波干扰的次数
- 超几何分布 (不放回抽样):  $N$  件产品中有  $M$  件不合格, 从  $N$  件产品中随机抽  $n$  件检查, 发现  $k$  件不合格品的概率

## (8) 若干个高斯分布相加/相乘后得到的分布是什么

假设多个随机变量分别服从不同的高斯分布, 如果这些随机变量**彼此独立**, 那么这些随机变量的和也服从高斯分布, 乘积为高斯分布乘以常数。

[https://blog.csdn.net/qg\\_41035283/article/details/121015712](https://blog.csdn.net/qg_41035283/article/details/121015712)

## (9) 期望和方差

- 期望: 随机变量的每个取值与其概率的乘积的累加和, 它描述了随机变量的集中特性。
- 方差: 随机变量的每个取值减去期望的平方与其概率的乘积的累加和, 它描述了随机变量的离散特性。
  - $D(X) = E((X - E(X))^2) = E(X^2) - E^2(X)$  (平方的期望-期望的平方)

## (10) 协方差和相关系数

- 协方差:  $X, Y$  的协方差等于每个  $X$  减去其平均值乘上每个  $Y$  减去其平均值的乘积的和的平均。

$$\begin{aligned} cov(X, Y) &= E[(X - E(X))(Y - E(Y))] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

- 意义: 协方差表示的是两个变量总体误差的期望, 当协方差为 0 时, 两者不线性相关; 协方差绝对值越大, 两者对彼此的影响越大 (>0 就是正相关, <0 就是负相关)
- $var(X + Y) = var(X) + var(Y) + 2cov(X, Y)$ ,  $var$  指方差
- 协方差矩阵:  $n$  维随机变量  $X = [X_1, X_2, \dots, X_n]^T$  的协方差矩阵为 ( $c_{ij} = cov(X_i, X_j)$ )

$$C = (c_{ij})_{n \times n} = \begin{pmatrix} c_{11} & c_{12} & \dots & c_{1n} \\ c_{21} & c_{22} & \dots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \dots & c_{nn} \end{pmatrix}$$

- 相关系数: 用  $X, Y$  的协方差除以  $X$  的标准差和  $Y$  的标准差

$$\rho_{X,Y} = \frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

- 意义：标准化的协方差，消除了两个变量量纲的影响，取值范围为  $[0, 1]$ 。

### (11) 独立和不相关的区别

- 独立：  $P(A|B) = P(A) \iff P(AB) = P(A)P(B)$
- 不相关：  $cov(X, Y) = E[XY] - E[X]E[Y] = 0$
- 独立一定不相关，而不相关不一定独立。**不相关就是两者没有线性关系**，但是不排除其它关系存在；**独立就是互不相干没有关联**。

### (12) 独立和互斥的关系

- 独立：  $P(AB) = P(A)P(B)$
- 互斥：  $A \cap B = \emptyset$
- 如果  $P(A) \neq 0, P(B) \neq 0$ ，则互斥不独立，独立不互斥。

### (13) 古典概型和几何概型的区别

- 古典概型——有限等可能（有限个可能事件，且每个事件都是等可能概率事件）
- 几何概型——无限等可能

### (14) 概率密度函数

- 连续型随机变量的取值有无穷多个实数，无法用分布列表示，所以用概率密度函数来表示。
- 概率密度函数不是概率，乘以区间长度微元后就表示概率的近似值。
- 概率密度函数在一段区间上的积分就是随机变量  $X$  在这段区间上取值的概率。

### (15) 极大似然估计

- 一种**参数估计**的方法，它先确定模型，通过若干次实验，观察其结果，反推最有可能（最大概率）导致这样结果的参数值。
- 似然方程的解只是一个估计值，只有在样本数趋于无限多的时候，它才会接近于真实值。
- 步骤：
  1. 写出似然函数
  2. 对似然函数取对数，并整理
  3. 求导数
  4. 解似然方程

## (16) 什么是假设和检验

- 假设检验：在总体分布函数未知的情况下，先对总体参数提出一个假设值，然后利用样本信息来判断这一假设是否成立。
- 基本思想：小概率事件在一次的实验中是不可能发生的。
- 两个假设：原假设（要检验的假设）、备选假设（拒绝原假设时的假设），他们是互补的。
- 两类错误
  - 第一类错误 (弃真错误)：原假设  $H_0$  为真，但是检验出的拒绝原假设，其概率为  $\alpha$ 。
  - 第二类错误 (存伪错误)：原假设  $H_0$  为假，但是检验出的接受原假设，其概率为  $\beta$ 。
  - 两类错误是相互矛盾的，不能同时降低两种错误，因此一般在限制  $\alpha$  的情况下，尽可能地降低  $\beta$  的值。
- 基本步骤
  1. 提出原假设和备选假设。
  2. 选取检验统计量。
  3. 给定显著性水平。
  4. 计算检验统计量的具体值，做出判断。

## (17) 机器学习为什么要使用概率？

- 机器学习的是由**数据驱动**的方法，它的学习对象是数据，从数据出发提取数据特征抽象出数据模型又从数据中发现知识，最后回到数据的分析和预测中去。
- 机器学习的**算法设计**通常依赖于对数据的概率假设。
- 机器学习模型的训练和预测过程的**评价指标**——模型误差，其本身就是概率的形式。

## (18) 不均匀硬币产生等概率

- 已知一随机发生器，产生 0 的概率是  $p$ ，产生 1 的概率是  $1-p$ ，现在要你构造一个发生器，使得它构造 0 和 1 的概率均为  $1/2$ 。
  - 连续随机生成两次，可能的情况有
    - 00:  $pp$
    - 01:  $p(1-p)$
    - 10:  $(1-p)p$
    - 11:  $(1-p)(1-p)$
  - 所以 2 次 1 组，认为 01 表示 0，10 表示 1，等概率，其他情况放弃。
- 扩展到 3, 4, ...,  $n$  同理，以 3 为例
  - 构造一个发生器，使得它构造 1, 2, 3 的概率均为  $1/3$ ：认为 001 表示 1，010 表示 2，100 表示 3，等概率，其他情况放弃。

### (19) 伪随机数产生均匀分布

混合同余法，其中  $m$  是模长， $a$  是乘数， $c$  是增量， $X_0$  是初始值。

$$X_n = (aX_{n-1} + b) \% m / m$$

### (20) 由均匀分布产生高斯分布

Box-Muller 算法，一共有两种形式，其中  $U_1, U_2$  是值域为  $(0, 1]$  的均匀分布的随机数， $Z_1, Z_2$  是高斯分布的随机数。

$$Z_0 = R \cos(\Theta) = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$$

$$Z_1 = R \sin(\Theta) = \sqrt{-2 \ln U_1} \sin(2\pi U_2).$$

## 3 微积分

[保研面试/考研复试高等数学问题整理 - 知乎 \(zhihu.com\)](#)

#### 格林公式 (Green formula)

若函数  $P(x, y), Q(x, y)$  在闭区域  $D$  上连续，且有一阶的连续偏导数，则有

$$\iint_D \left( \frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dx dy = \oint_L P dx + Q dy, \text{ 这里 } L \text{ 为闭区域的边界曲线并取正向。}$$

#### 高斯公式 (Gauss formula)

设空间闭区域  $V$  由分片光滑的双侧封闭曲面  $S$  围成，若函数  $P, Q, R$  在  $V$  上连续，且有一阶的连续偏导数，则  $\iiint_V \left( \frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z} \right) dx dy dz = \iiint_S P dy dz + Q dx dz + R dx dy,$

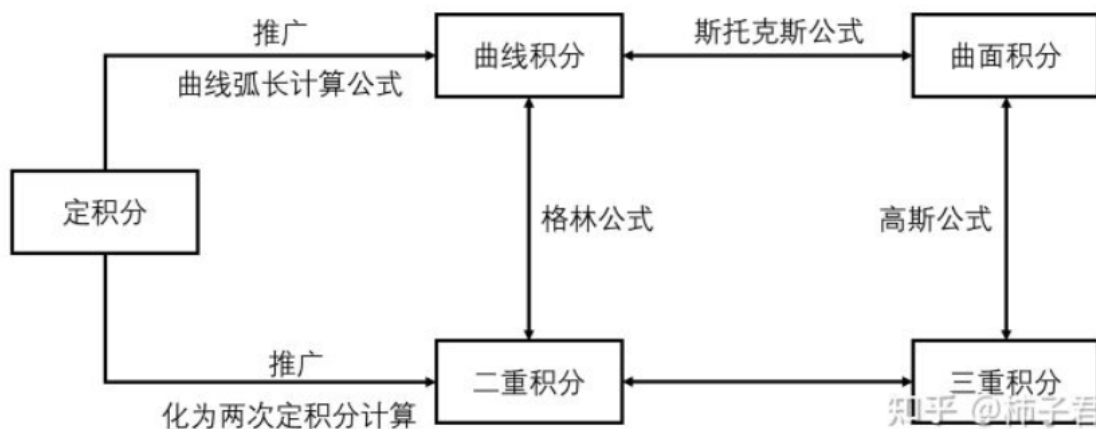
其中  $S$  取外侧。

#### 斯托克斯公式 (Stokes formula)

设光滑曲面  $S$  的边界  $L$  是按段光滑的连续曲线，若函数  $P, Q, R$  在  $S$  (连同  $L$ ) 上连续，且有一阶的连续偏导数，则

$$\oint_L P dx + Q dy + R dz = \iint_S \left( \frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) dy dz + \left( \frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) dz dx + \left( \frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dx dy$$

，其中  $S$  的侧与  $L$  的方向按右手法则确定。



## 4 离散数学

### (1) 自反、对称、传递

- 假设集合A, 以及基于A上的关系R
  - 自反: 如果a是A的元素, 那么 $\langle a, a \rangle$ 是R的元素
  - 对称: 如果 $\langle a, b \rangle$ 是R的元素, 那么 $\langle b, a \rangle$ 是R的元素
  - 传递: 如果 $\langle a, b \rangle, \langle b, c \rangle$ 是R的元素, 那么 $\langle a, c \rangle$ 是R的元素

### (2) 对称传递能不能推出自反性?

不能

### (3) 自反性存在有什么意义?

自反性是等价关系的基石。

### (4) 等价关系和等价类

自反+对称+传递

### (5) 偏序关系

自反+反对称+传递